ScholarMind

RAG 기반 논문 탐색 및 요약 시스템 — 졸업작품 최종 발표

발표자: 강상연

1차 발표

Ragxiv

arXiv 검색 · Qwen2.5 1.5B · CPU 추론

영어 전용 임베딩 · 벡터 검색 단독

현재

ScholarMind

Semantic Scholar 검색 · EXAONE 3.5 2.4B

내장 그래픽 가속 · 하이브리드 검색 · 단계별 시간 측정

지난 발표 피드백 반영

피드백 1

단계별 시간 측정

질문할 때마다 7단계 소요 시간을 답변 아래 표로 표시

측정으로 요청마다 2.15초가 새던 곳을 발견 → 첫 질문 47초 → 25초

피드백 2

사용 모델 설명

EXAONE(LG)과 Kanana(카카오) — 둘 다 국내 기업이 공개한 한국어 특화 모델

모델 크기에 따른 속도·품질 차이를 실험으로 확인

ScholarMind

피드백 1 · 단계별 시간 측정 기능

⏱ 단계별 소요 시간 · 총 48.6초

단계	시간
질문 판별	4.0초
검색어 생성	2.1초
논문 검색	7.7초
논문 선택	6.8초
PDF·인덱싱	15.8초
근거 검색 · 첫 글자	5.1초
답변 출력	7.1초
합계	**48.6초**

구현

질문마다 자동 측정 · 기록

timing.py — 단계가 끝날 때마다 경과 시간을 기록 (lap)

화면: 답변 아래 표 · 파일: logs/timings.jsonl

코드 버전별로 수정 전후 비교 (compare_timings.py)

이 질문에서 보인 것

네트워크가 48%

논문 검색 7.7초

PDF·인덱싱 15.8초

새 논문을 받으면 와이파이가 좌우

측정으로 찾은 것

47초 → 25초

localhost 접속마다 2.15초 지연

127.0.0.1로 바꿔 약 13초 제거

피드백 2 · 사용한 언어 모델

LG AI연구원 · 2024년 12월 공개

EXAONE 3.5

2.4B · 7.8B · 32B 세 가지 크기

한국어·영어 이중언어 학습, 긴 문맥 32K 토큰

연구 목적 무료 — 상업 이용은 별도 계약

ScholarMind 기본 모델 (2.4B, 노트북 실행)

카카오 · 2025년 공개

Kanana

Kanana 1.5 기준 2.1B · 8B 크기

한국어 이해·생성에 강점, 오픈 라이선스

데스크톱(RTX 4060 Ti)에서 8B로 비교 실험

최신 용어(Agentic AI)를 바꾸지 않고 검색

모델 크기 B = 파라미터 10억 개

크면 지식·품질이 좋아지지만 느려짐 — 2.4B는 노트북 내장 그래픽에서 질문 1회 약 25초, 8B는 노트북에서 실용 속도가 안 나옴

왜 RAG인가 — 검색 증강 생성

기존 LLM

내부 지식에만 의존

학습한 지식으로만 답함

그럴듯하지만 틀린 답(환각) 위험

출처를 확인할 수 없음

학습 이후 나온 논문은 모름

ScholarMind

논문 원문에 근거해 답변

질문마다 논문을 검색해 원문 PDF 확보

관련 문단만 찾아 모델에 전달

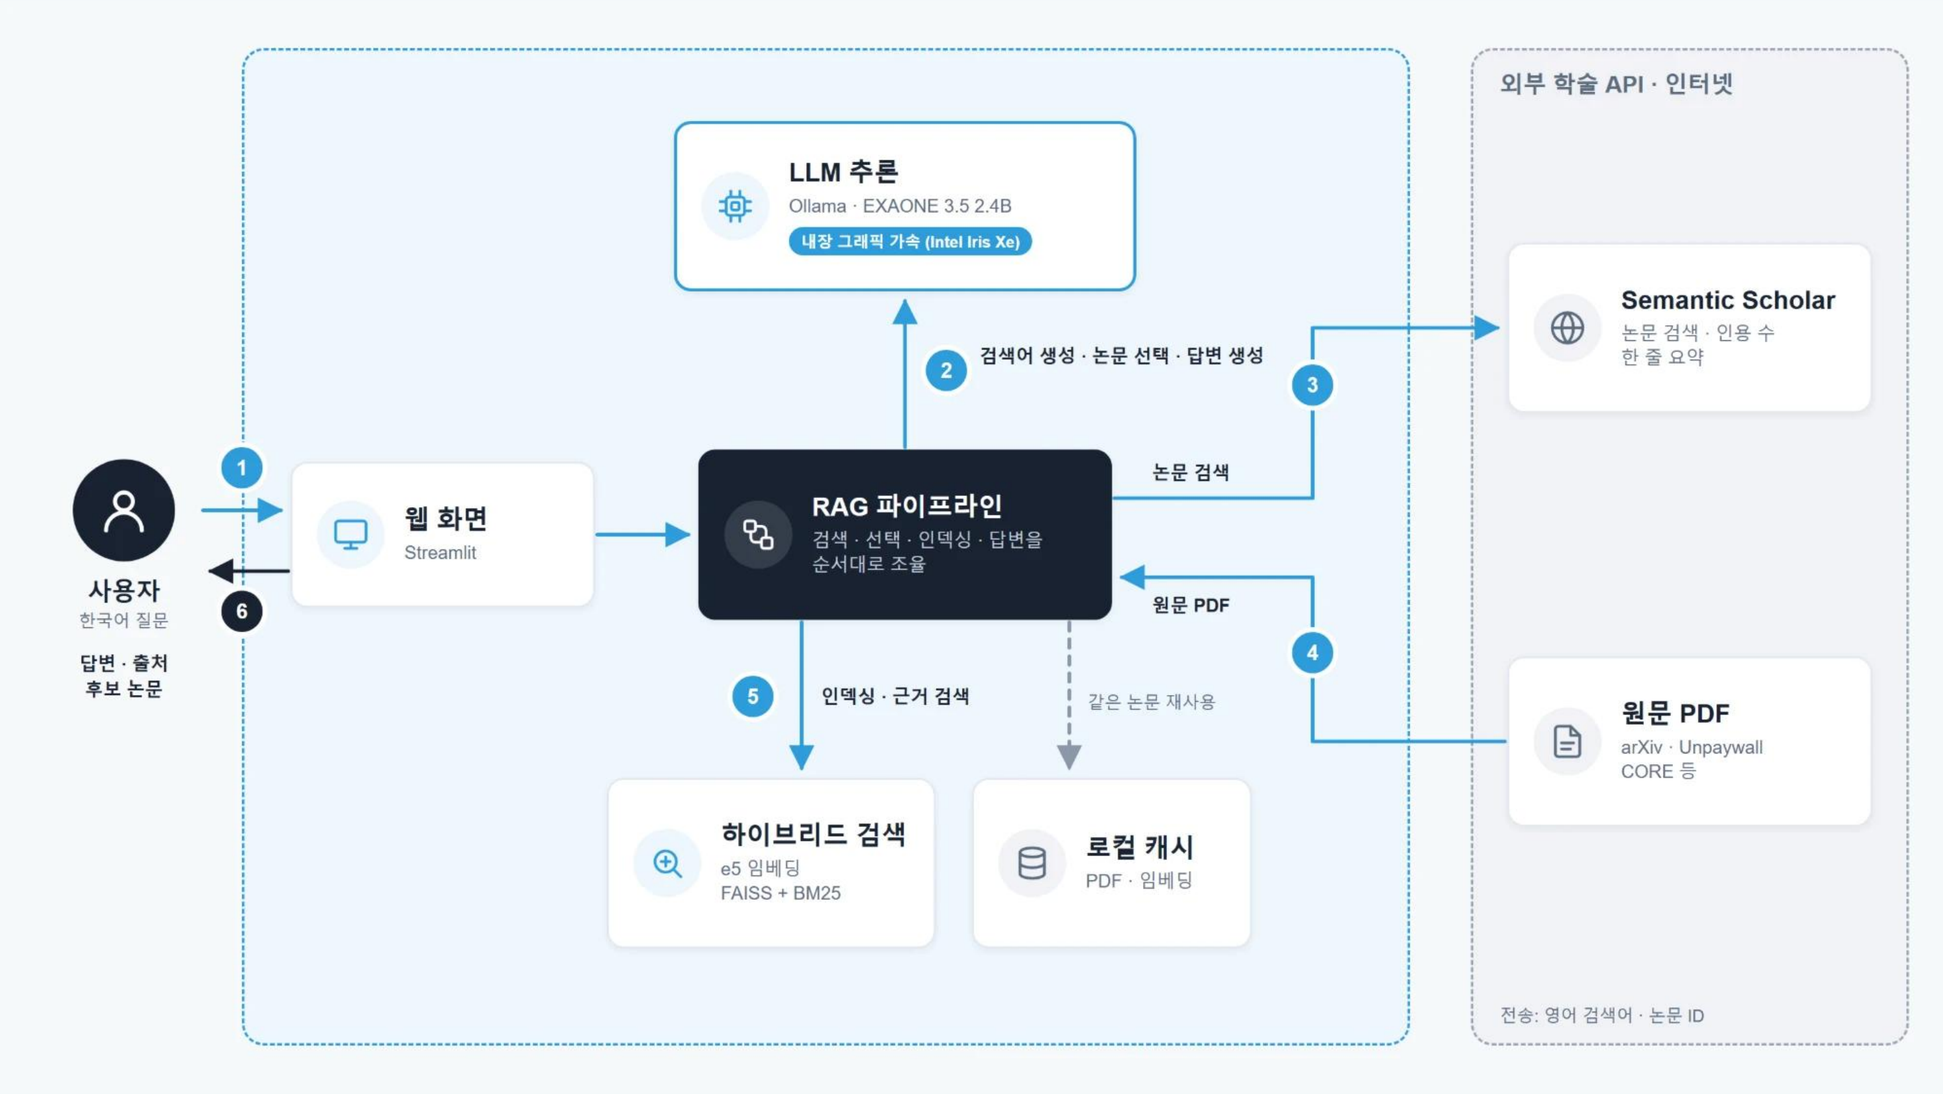
주어진 문단 안에서만 답하도록 지시

답변에 논문 출처를 함께 표시

Ragxiv에서 ScholarMind로

	Ragxiv (1차)	ScholarMind (현재)
논문 출처	arXiv — 심사 전 논문만	**Semantic Scholar + 신뢰도 필터**
언어 모델	Qwen2.5 1.5B — 중국어 혼입	**EXAONE 3.5 2.4B — 한국어 네이티브**
검색	영어 전용 임베딩 · 벡터 단독	**한·영 임베딩 + BM25 하이브리드**
출력	완성 후 일괄 출력	**스트리밍 · 후보 논문 바꿔 다시 답하기**
실행 · 검증	CPU · 수동 확인	**내장 그래픽 가속 · 자동 점검 44항목**

시스템 아키텍처


외부 학술 API · 인터넷
LLM 추론
Ollama · EXAONE 3.5 2.4B
내장 그래픽 가속 (Intel Iris Xe)
Semantic Scholar
논문 검색 · 인용 수
한 줄 요약
2
검색어 생성 · 논문 선택 · 답변 생성
3
논문 검색
1
사용자
한국어 질문
6
답변 · 출처
후보 논문
웹 화면
Streamlit
RAG 파이프라인
검색 · 선택 · 인덱싱 · 답변을
순서대로 조율
원문 PDF
4
원문 PDF
arXiv · Unpaywall
CORE 등
5
인덱싱 · 근거 검색
같은 논문 재사용
하이브리드 검색
e5 임베딩
FAISS + BM25
로컬 캐시
PDF · 임베딩
전송: 영어 검색어 · 논문 ID

ScholarMind

질문 하나가 처리되는 과정

1
질문 판별
후속 질문이면 바로 답변

2
검색어 생성
한국어 질문 → 영어 키워드

3
논문 검색
Semantic Scholar 신뢰도 필터

4
논문 선택
LLM이 후보 10편 중 1편

5
PDF·인덱싱
원문 확보 · 청크 분할

6
근거 검색
FAISS + BM25 · 문장 압축

7
답변 출력
스트리밍 · 출처 표시

파란 단계 = LLM 사용 , 회색 단계 = 검색 · 네트워크

7개 단계가 곧 시간 측정 기준 — 어느 단계가 느린지 질문마다 바로 확인

제한된 노트북에서의 모델 선정

1차 시도

Phi-3-Mini

3.8B

노트북 메모리 부족으로 충돌

2차 시도

Llama-3.2

1B

학습한 어휘가 좁아 지시 수행 붕괴

언어 혼용 · 반복 출력

3차 · 중간발표

Qwen2.5

1.5B

안정적이지만 한국어에 중국어 혼입

현재

EXAONE 3.5

2.4B

한국어 기반

내장 그래픽으로 속도 확보

검색 정확도 개선

교차언어 검색

한국어 질문 ↔ 영어 논문

영어 전용 BGE → multilingual-e5-small

한국어 질의와 영어 본문을 같은 벡터 공간에 정렬

질문엔 query:, 본문엔 passage: 접두사

한국어 질의 ↔ 영어 본문 유사도 0.74

하이브리드 검색

BM25 + 벡터 검색

벡터 검색은 약어·고유명사 정확 매치에 약함

BM25 어휘 검색을 함께 사용

두 순위를 RRF(k=60)로 융합 — 점수 정규화 불필요

BM25는 신경망이 아니라 추가 비용 거의 없음

논문 품질 보증 체계

1단계 **신뢰도 필터**	**STRICT → BALANCED → OFF 자동 완화** DOI 또는 게재처 보유 · 피인용 5회 이상 · 최근 6개월 이내 발표 중 하나를 충족
2단계 **PDF 확보 캐스케이드**	**arXiv → openAccessPdf → Unpaywall → CORE** 순차 시도 후 %PDF 매직넘버로 검증 — HTML 오류 페이지 저장 차단
3단계 **메타데이터 교차검증**	**arXiv ID 연도 vs 게재 연도 대조** 외부 DB의 잘못된 논문 연결을 탐지해 인용 정보에 경고 표시

답변 신뢰성 문제 해결

문제 — 질문을 되풀이하는 선택 이유

순환 논리

해결: 논문의 방법·데이터셋·발견을 근거로 들도록 규칙 추가

문제 — 내용이나 주제가 포함됐는데도 단서를 붙임

반사적 회피 표현

해결: 논문이 실제로 해당 내용이나 주제를 다루면 단정적으로 답하도록 조건부 규칙

문제 — 부록의 실험 설정이 검색됨

요약 질의 환각

해결: 요약 질의는 문서 앞부분(초록·서론)을 근거로 사용

문제 — 표의 숫자를 다른 지표로 읽음

지표 오독

해결: 답변의 수치를 원문과 대조해 의심되면 경고 표시

ScholarMind

응답 속도 개선

3.1배

논문 선택

CPU 29.6초 → 내장 그래픽 9.5초

1.8배

답변 생성

CPU 16.5초 → 내장 그래픽 9.1초

47 → 25초

실제 첫 질문

localhost 지연 제거 (요청마다 2.15초)

추가 하드웨어 없이

노트북 내장 그래픽(Intel Iris Xe) + Ollama Vulkan

프롬프트 읽기 초당 70토큰 → 340토큰 · CPU와 같은 논문 선택 14개 중 13개 — 품질 유지

문장 압축으로 문맥 84% 감소(4,443자 → 713자) · 임베딩 모델 오프라인 로드 9.0초 → 1.6초

실행 환경 비교 — 같은 질문, 네 가지 구성

47초

노트북 · EXAONE 2.4B

Intel Iris Xe · 첫 질문

17초

데스크톱 · EXAONE 2.4B

RTX 4060 Ti

32초

데스크톱 · Kanana 8B

RTX 4060 Ti

66초+

데스크톱 · Kanana 8B

MCP 에이전트 방식

결론

속도는 장치가, 품질은 모델이 결정

EXAONE 2.4B: "Agentic AI"를 "Agent-Based AI"로 바꿔 검색 — 노트북·데스크톱 동일, 모델의 한계

Kanana 8B: 용어를 그대로 유지해 주제에 맞는 논문을 찾음

질문: "Agentic ai에 대해서 알려줘" · 노트북 47초는 localhost 지연 수정 전 — 수정 후 25초

자동 검증 체계

44 / 44

시스템 점검 통과

healthcheck.py — 의존성 · 모델 응답 · 검색 · 시간 측정 · 화면 기동

76 / 76

고장 주입 검출

verify_healthcheck.py — 일부러 고장을 넣어 검사가 실제로 잡는지 역검증

10개 질문

자동 실행 · 채점

run_questions.py — 키워드 형식 · PDF 확보 · 답변 언어 등 7가지 자동 판정

수동 검증 30분 → 리포트 확인 3분

고장 주입으로 아무것도 잡지 못하던 검사 3개를 찾아 수정 · 외부 API 장애는 코드 결함과 분리해 판정

남은 한계와 향후 계획

남은 한계

모델 지식과 네트워크

2.4B 모델은 최신 신조어를 모름 — Agentic AI

논문 선택이 실행마다 달라질 수 있음

새 논문 PDF를 받는 질문은 와이파이가 속도 좌우

답변 적합성·환각은 사람이 최종 확인

향후 계획

검색어 보존과 반복 측정

사용자가 영어로 쓴 용어는 검색어에 그대로 보존

시간 기록을 쌓아 단계별 반복 측정·비교

여러 논문 비교 · 북마크 기능

검색 결과 캐시로 시연 안정성 확보

// demo — 졸업작품 시연

SCHOLARMIND

논문을 찾고, 읽고,
답해주는 ScholarMind

내 노트북 한 대로 돌아가는 논문 탐색 · 요약 시스템



기존 논문 사이트와 비교한 강점

	Google Scholar 등 검색 사이트	클라우드 AI 논문 서비스	ScholarMind
결과 형태	논문 목록 · 초록	AI 요약 답변	**원문 근거 답변 + 출처**
한국어로 묻고 답하기	영어 키워드 필요	서비스마다 다름	**한국어 질문 → 영어 검색 자동**
질문 내용	검색 서버로 전송	질문 전체가 외부 서버로	**노트북 안에서 처리**
비용	무료	월 구독 · 사용량 제한	**무료 · 일반 노트북**
논문 신뢰도	직접 판단	서비스 기준 비공개	**DOI·피인용 필터 공개**

한국어 질문 하나로 원문 근거 답변까지 — 질문 내용은 노트북 밖으로 나가지 않음

감사합니다

Q & A